


# ВВЕДЕНИЕ В МАШИННОЕ ОБУЧЕНИЕ

Лекция №9





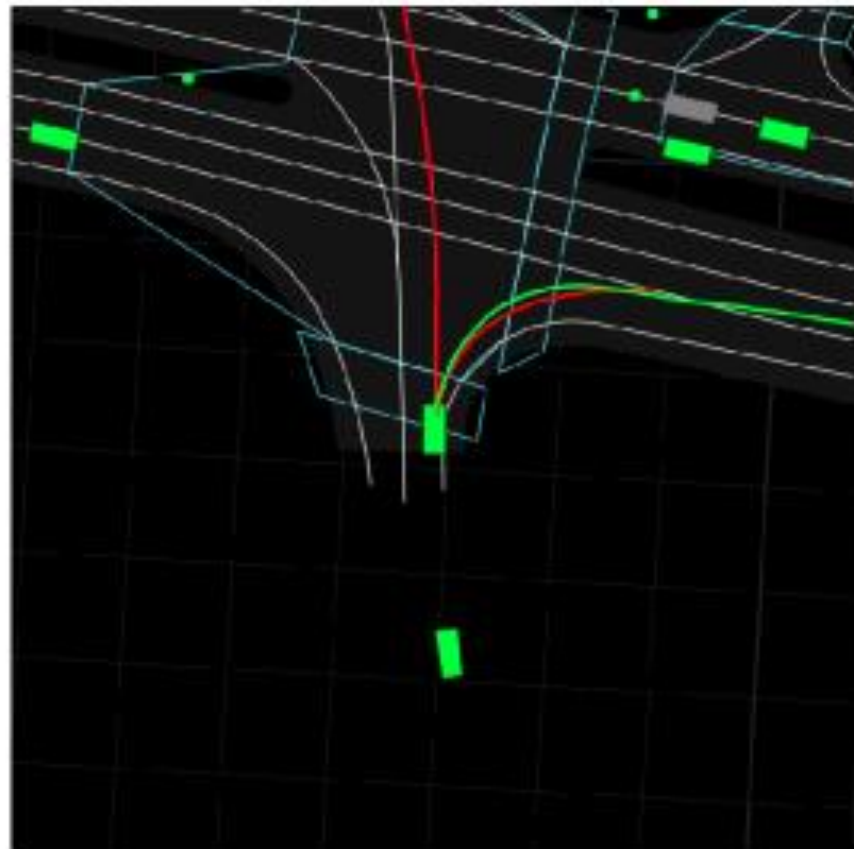
01



# Задача ранжирования и матчинга

# Ранжирование

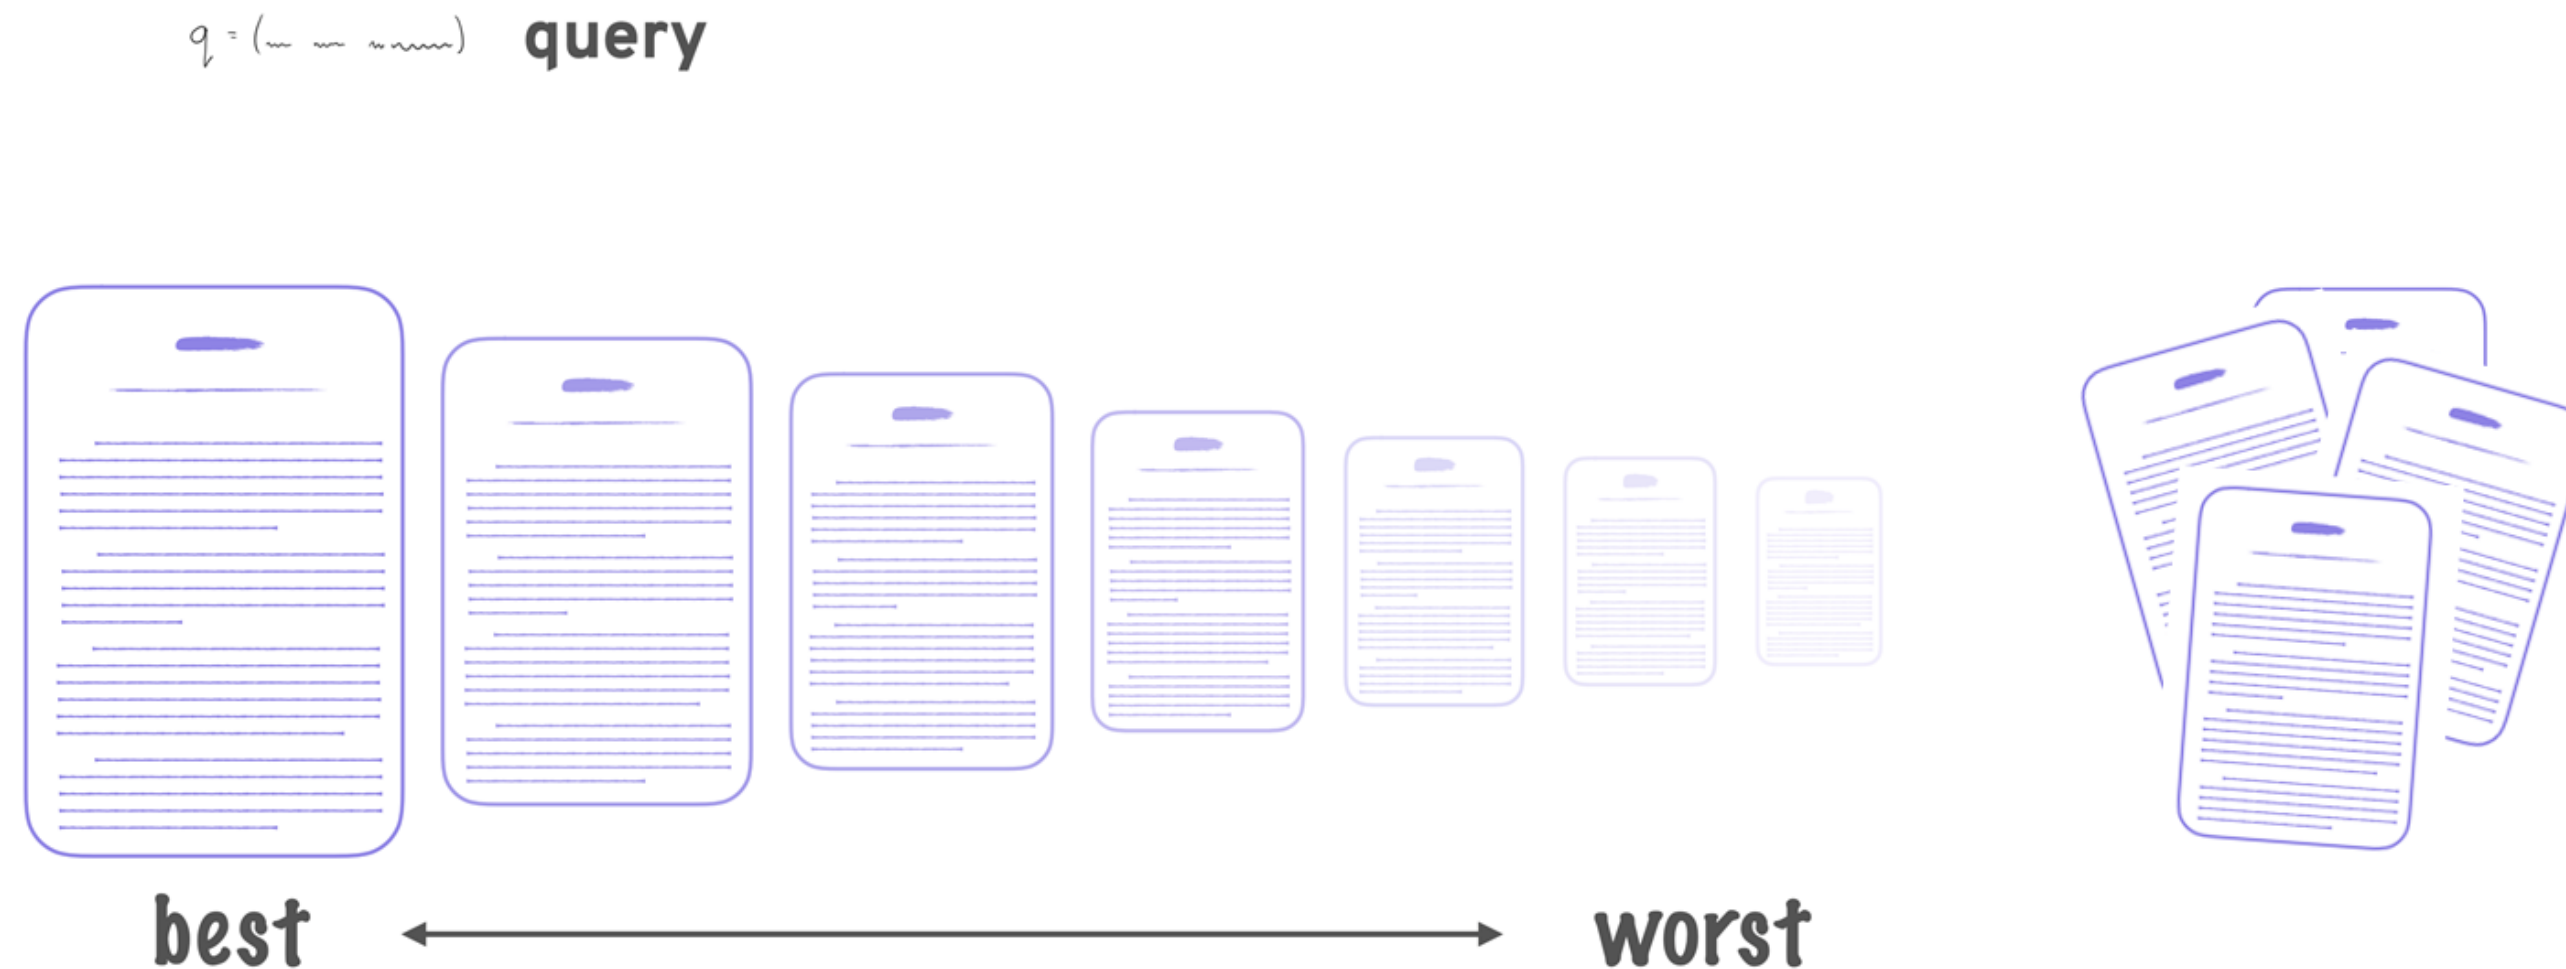
**Ранжирование** — процесс упорядочивания набора объектов в соответствии с некоторой мерой, то есть задание частично упорядоченного множества.



# Порядок имеет значение

Множество частично упорядочено, если указано, какие элементы следуют за какими (какие элементы больше каких).

В общем случае может оказаться так, что некоторые пары элементов не связаны отношением «следует за»

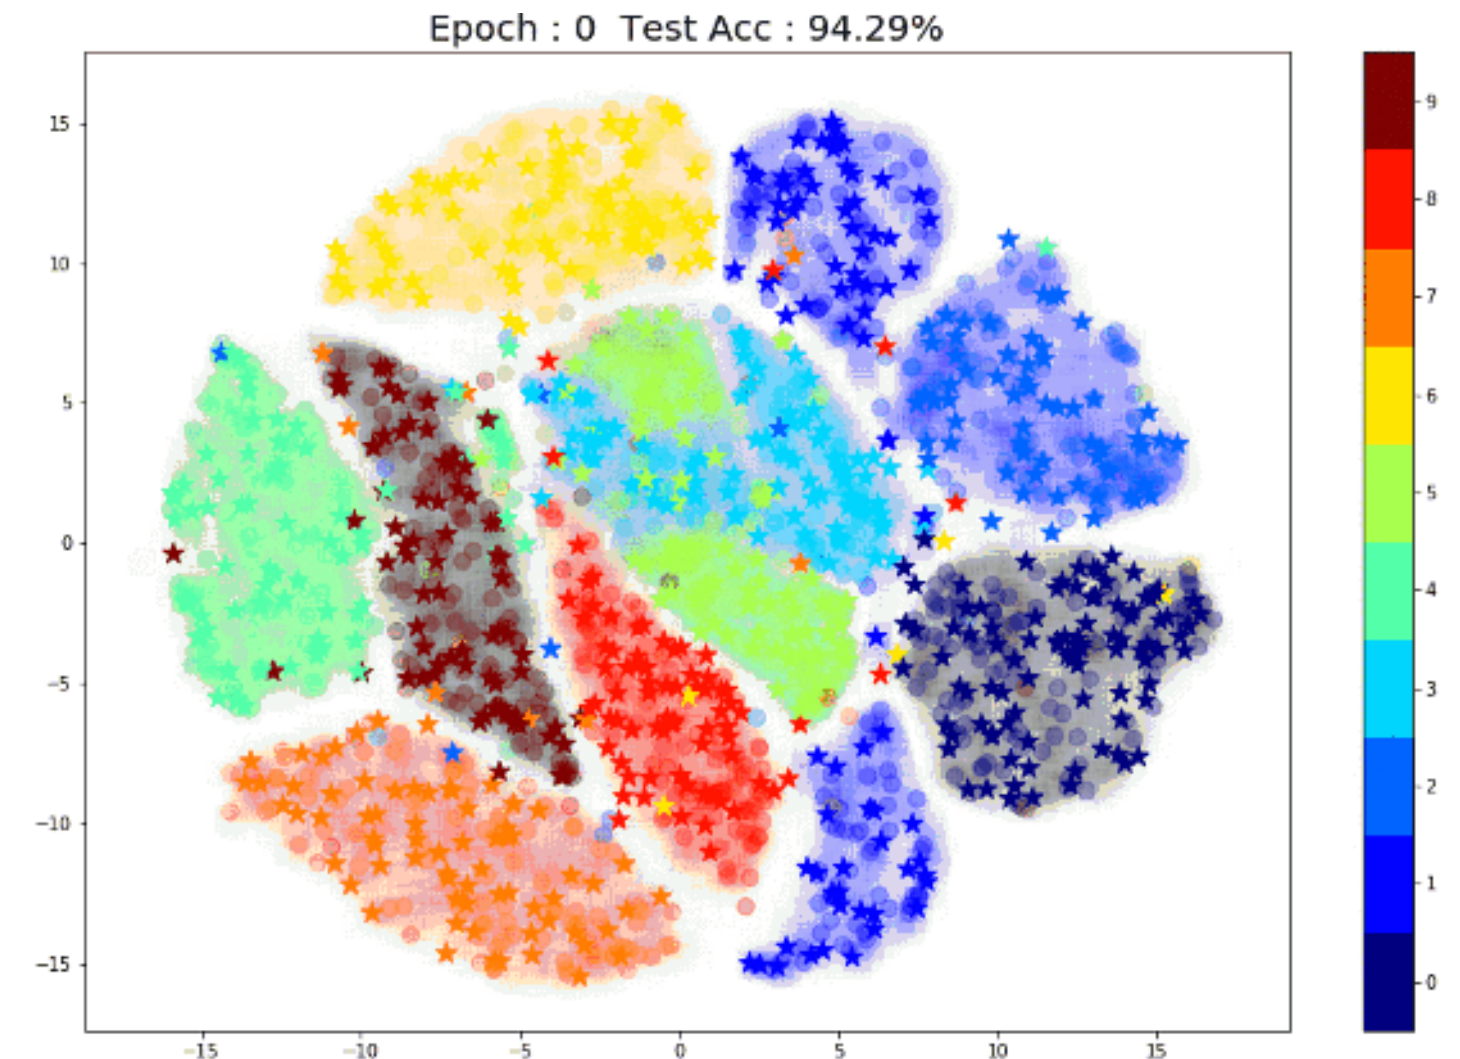


# Место задачи ранжирования

**Learning to rank** (обучение ранжированию) — класс задач машинного обучения с учителем (*supervised*) или с частичным привлечением учителя (*semi-supervised*), Цель — построить модель, которой является наилучшим приближением и обобщением способа ранжирования в обучающей выборке для новых данных.

*Pseudo-labeling* — одна из техник *semi-supervised* обучения

$$\text{Loss per Batch} = \text{Labeled Loss} + \text{Weight} * \text{Unlabeled Loss}$$






# Постановка задачи

**Мера релевантности** — степень соответствия между запросом и документом (или набором документов).

Чем выше это соответствие, тем выше в списке ранжирования должен находиться документ.

$$\text{Relevance}(\text{query}, \text{doc}) \sim \langle \text{Emb}^n(\text{query}), \text{Emb}^n(\text{doc}) \rangle$$



# Постановка задачи LTR

**Задача (learning to rank – LTR)** — создание глобальной модели  $F(q, D)$ , которая будет работать над всем корпусом документов.

$Q$  – набор запросов  $\{q_1, q_2, \dots, q_m\}$

$D$  – набор документов

$D_i = \{d_{i,1}, d_{i,2}, \dots, d_{i,n_i}\}$  – набор документов, релевантных  $i$  запросу  $q$

$d_{i,j}$  – элемент с индексом  $j$  в  $D_i$

$y_i = \{y_{i,1}, y_{i,2}, \dots, y_{i,n_i}\}$  – набор оценок релевантности для  $i$  запроса (размер тот же, что и у  $D_i$ )

$S = \{(q_i, D_i), y_i\}_{i=1}^m$  – тренировочный набор данных

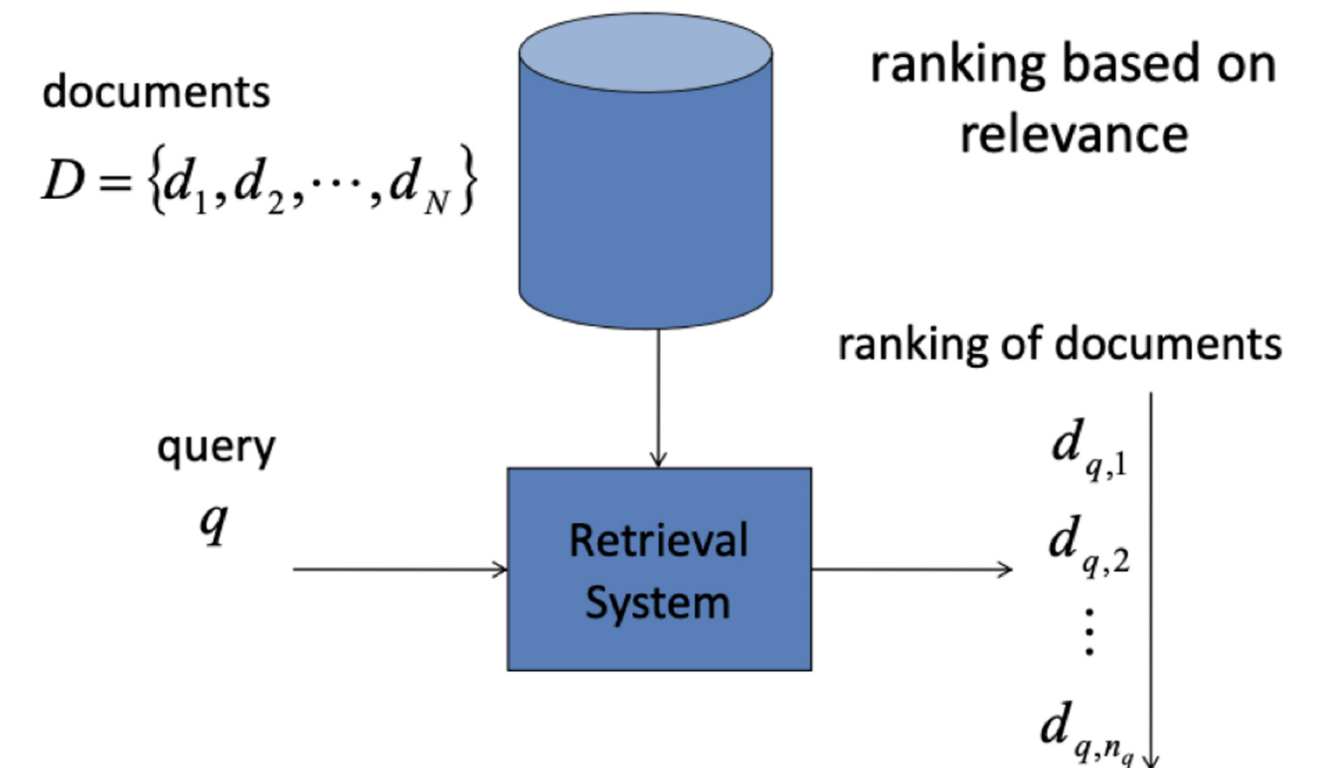
$x_{i,j} = \phi(q_i, d_{i,j})$  – вектор признаков для  $i$  запроса и  $j$  документа ( $i = 1, \dots, m, j = 1, \dots, n_i$ )

$\phi$  – функция для получения признаков (BM25, PageRank, мультимодальные модели)

$x_i = \{x_{i,1}, x_{i,2}, \dots, x_{i,n_i}\}$  – признаки набора документов, релевантных  $i$  запросу  $q$

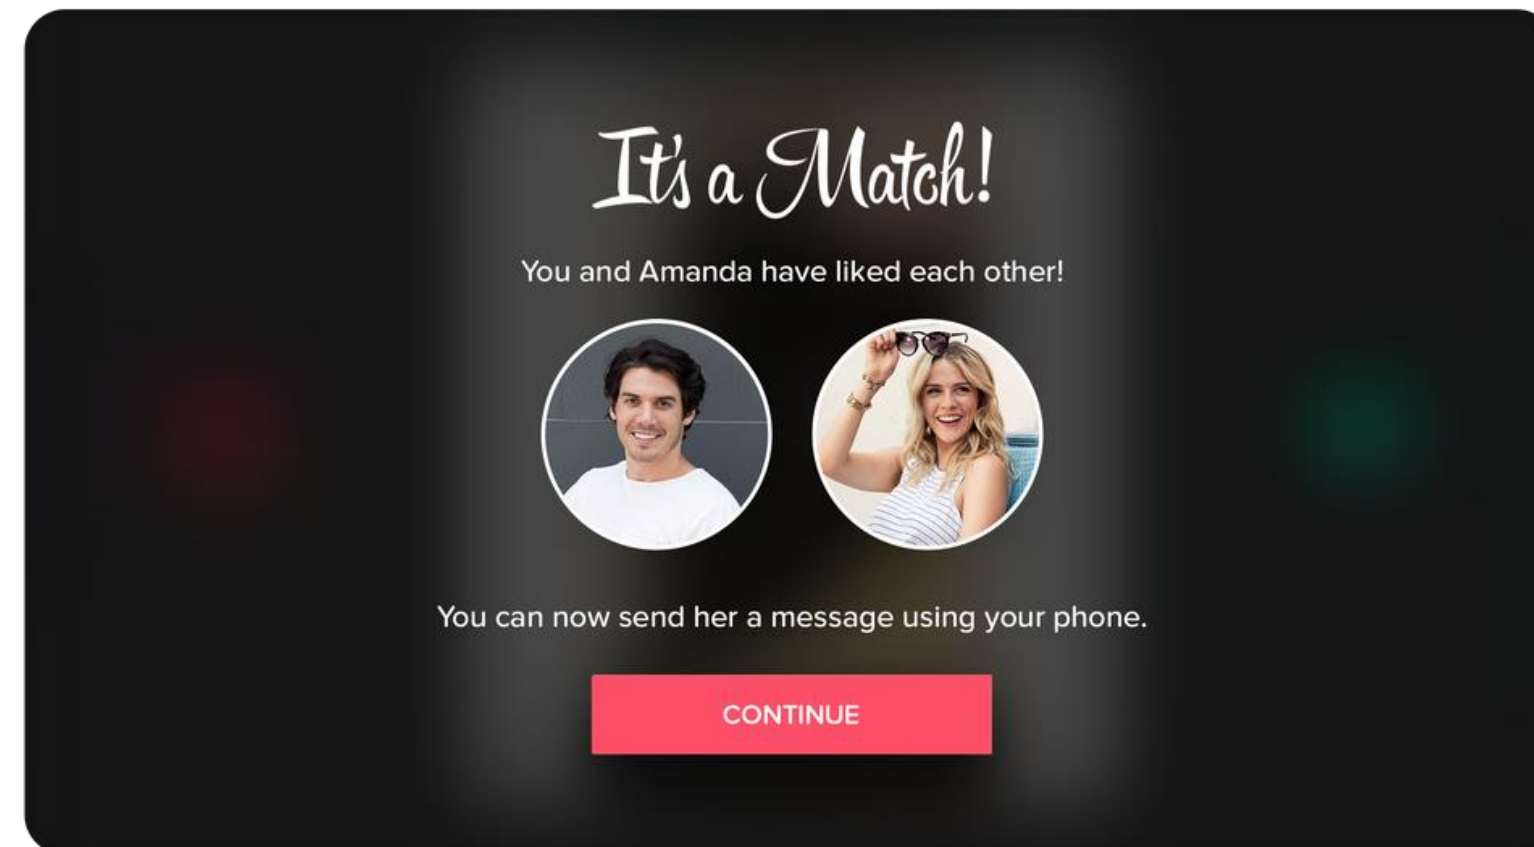
$f(q, d) = f(x)$  – ранжирующая модель, оценивающая релевантность для пары  $q, d$  на основе признаков  $x$

$F(q, D) = F(x)$  – глобальная ранжирующая модель



# Сопоставление == Матчинг

**Матчинг** — процесс сопоставления объектов на основе сравнения и расчета некоторой меры схожести, где объекты, с одной стороны, представляют собой «запросы», а с другой — «документы».





# Применимость матчинга

- Ценообразование;
- Мониторинг промоакций;
- Ассортиментное планирование;
- Мониторинг рынка (в том числе и со стороны производителя);
- Реализация функционала маркетплейса;
- Оперативный поиск.

## СмакВил



- Товар «Чусовой (чёрный) хлеб»  
Цена - 11.2 рублей  
Масса - 220 грамм  
Поставщик – ООО «Моя оборона»
- ...

9

## Алфавит Послевкусия



- Товар «Хлеб Чусовой Черный»  
Цена - 13.5 рублей  
Масса - 220 грамм  
Поставщик - ?
- ...

# Уникальный индекс – SKU

**SKU** (*Stock Keeping Unit*, складская учётная единица) — идентификатор товарной позиции (*артикул*), единица учёта запасов, складской номер, используемый в торговле для отслеживания статистики по реализованным товарам/услугам.

Каждой продаваемой позиции, будь то товар, вариант товара, комплект товаров (продаваемых вместе), услуга или некий взнос, назначается свой SKU.

**SKU** не всегда ассоциируется с физическим товаром,<sup>10</sup> являясь скорее идентификатором сущности, представляемой к оплате.

Электроника • Смартфоны и гаджеты • Мобильные телефоны • Apple

## Смартфон Apple iPhone 14 128 ГБ, тёмная ночь

Выбор покупателей

4.9 111 отзывов Характеристики 148 вопросов экран, качество фотографий 663 500 человек интересовались за 2 месяца



Цвет товара: Тёмная ночь

Версия: Для других стран

Ростест (ЕАС) для других стран

Конфигурация памяти: 128 ГБ

128 ГБ 256 ГБ 512 ГБ

Количество SIM-карт: Dual SIM (nano-SIM + eSIM)

Dual SIM (nano-SIM + eSIM)

Dual SIM (nano-SIM) Dual SIM (eSIM)

Коротко о товаре

Экран	6.1" (2532x1170) OLED
Память	встроенная 128 ГБ
Фото	двойная камера, основная 12 МП
Процессор	Apple A15 Bionic
SIM-карты	Dual SIM (nano-SIM + eSIM)
Беспроводные интерфейсы	NFC, Bluetooth, Wi-Fi



# Предложение о продаже

Одна модель может содержать несколько SKU

Весь ассортимент – база документов  
Все предложения – набор запросов

Мультимодальные данные – данные разной природы

Электроника

Смартфоны и гаджеты

Мобильные телефоны

iPhone 14

Результаты поиска во всех категориях

Мобильные телефоны

Электроника

Смартфоны и гаджеты

Мобильные телефоны (800)

Все результаты поиска

Цена, ₽

от 4 490

до 174 403

Срок доставки

☐ Сегодня или завтра

☐ До 5 дней

☒ Любой

Чёрная пятница

70%

Можно оплатить частями

Производитель

☐ Apple

☐ HONOR

☐ OnePlus

☐ Samsung

☐ Ulefone

☐ vivo

☐ Xiaomi

Скидки и акции

☐ кешбек баллами Плюса

☐ скидки

Со склада Яндекс

☐ С доставкой Яндекс

Состояние товара

☐ Новый

☐ Ресейл

Внешний вид

☐ Как новый

☐ Отличный

☐ Хороший

Линейка

☐ iPhone 12

☐ iPhone 14

☐ iPhone 14 Plus

☐ iPhone 14 Pro

☐ iPhone 14 Pro Max

Ещё 24

Операционная система

☐ Android

☐ iOS

Диагональ экрана

☐ 3.5"-4.9"

☐ 5.0"-5.4"

☐ 5.5"-5.9"

Ещё 2

по популярности

по цене

по рейтингу

по скидке

☐ Сначала мой регион

Выбор покупателей

Смартфон Apple iPhone 14 128 ГБ, синий

Экран: 6.1" (2532x1170) OLED

Память: встроенная 128 ГБ

Фото: двойная камера, основная 12 МП

Процессор: Apple A15 Bionic

Сет. карты: Dual SIM (nano-SIM + eSIM)

4.9/110

663 тыс человек интересовались за 2 месяца

59870₽ - 599

Доставка завтра [42]

MOBILE-ROOMS.RU 4.9/5K

В корзину

88 предложений от 59499₽

Выбор покупателей

Смартфон Apple iPhone 14 128 ГБ, фиолетовый

Экран: 6.1" (2532x1170) OLED

Память: встроенная 128 ГБ

Фото: двойная камера, основная 12 МП

Процессор: Apple A15 Bionic

Сет. карты: Dual SIM (nano-SIM + eSIM)

4.9/110

663 тыс человек интересовались за 2 месяца

59670₽ - 599

Доставка завтра [42]

MOBILE-ROOMS.RU 4.9/5K

В корзину

92 предложения от 59660₽

Выбор покупателей

Смартфон Apple iPhone 14 128 ГБ, тёмная ночь

Экран: 6.1" (2532x1170) OLED

Память: встроенная 128 ГБ

Фото: двойная камера, основная 12 МП

Процессор: Apple A15 Bionic

Сет. карты: Dual SIM (nano-SIM + eSIM)

4.9/110

663 тыс человек интересовались за 2 месяца

58990₽ - 590

Доставка завтра [42]

MOBILE-ROOMS.RU 4.9/5K

В корзину

79 предложений от 58990₽

Выбор покупателей

Смартфон Apple iPhone 14 128 ГБ, сияющая звезда

Экран: 6.1" (2532x1170) OLED

Память: встроенная 128 ГБ

Фото: двойная камера, основная 12 МП

Процессор: Apple A15 Bionic

Сет. карты: Dual SIM (nano-SIM + eSIM)

4.9/110

663 тыс человек интересовались за 2 месяца

58980₽ - 590

Доставка завтра [42]

MOBILE-ROOMS.RU 4.9/5K

В корзину

79 предложений от 58970₽

Выбор покупателей

Смартфон Apple iPhone 14 128 ГБ, (PRODUCT)RED

Экран: 6.1" (2532x1170) OLED

Память: встроенная 128 ГБ

Фото: двойная камера, основная 12 МП

Процессор: Apple A15 Bionic

Сет. карты: Dual SIM (nano-SIM + eSIM)

4.9/110

663 тыс человек интересовались за 2 месяца

59820₽ - 599

Доставка завтра [42]

MOBILE-ROOMS.RU 4.9/5K

В корзину

59 предложений от 59800₽

Выбор покупателей

Смартфон Apple iPhone 14 256 ГБ, синий

Экран: 6.1" (2532x1170) OLED

Память: встроенная 256 ГБ

Фото: двойная камера, основная 12 МП

Процессор: Apple A15 Bionic

Сет. карты: Dual SIM (nano-SIM + eSIM)

4.9/110

663 тыс человек интересовались за 2 месяца

67490₽ - 675

Доставка завтра [42]

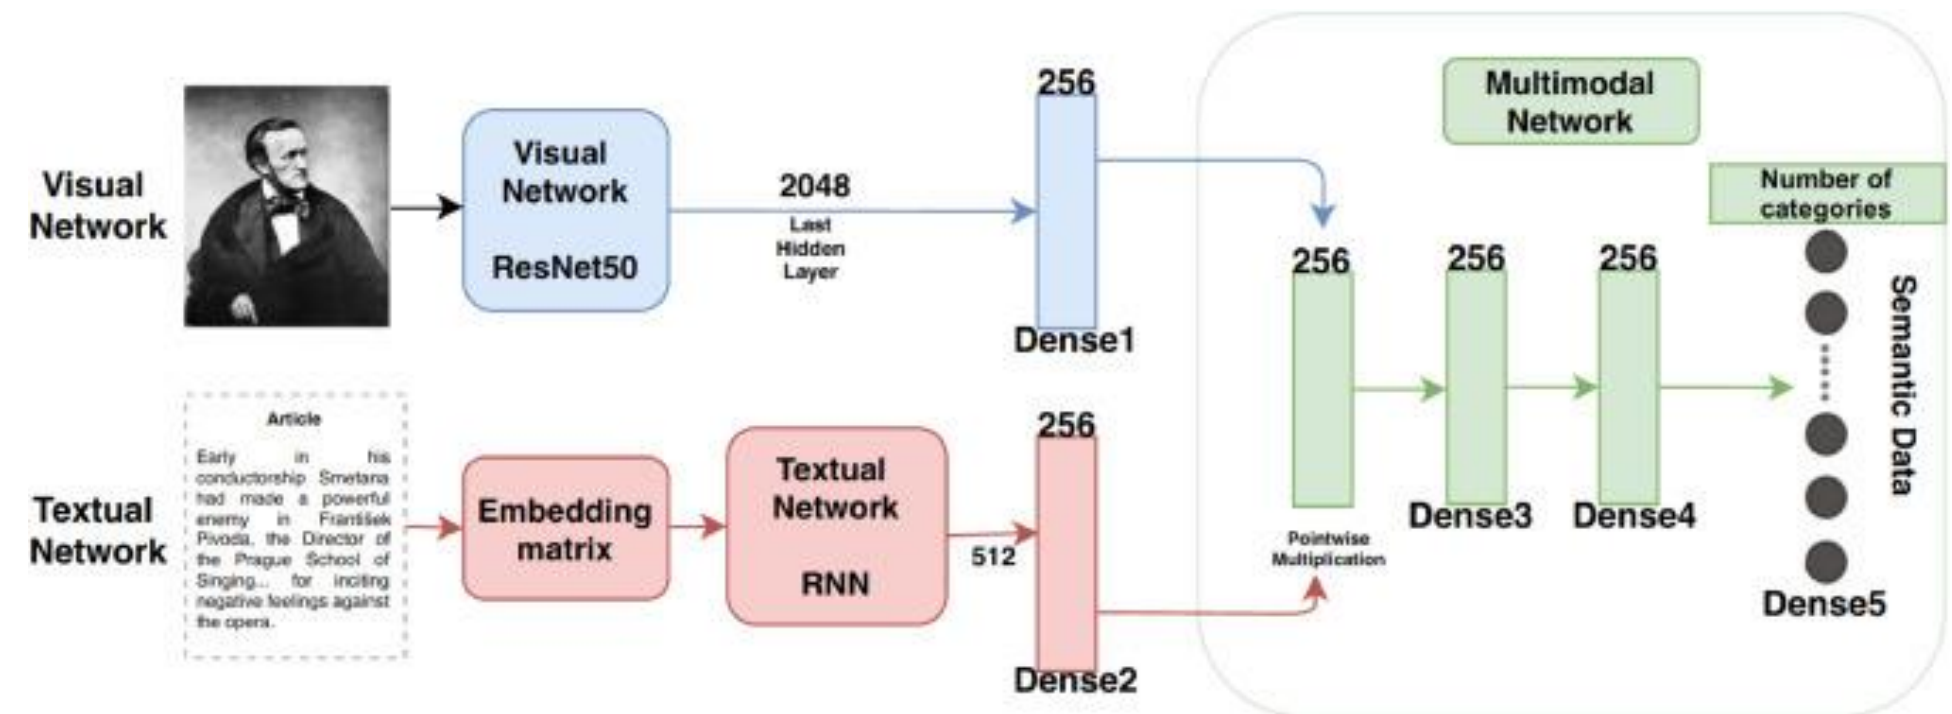

MOBILE-ROOMS.RU 4.9/5K

В корзину

55 предложений от 67490₽

# Мультимодальные модели

**Мультимодальные модели** — модели, которые принимают и обрабатывают совместно данные разной природы; они оперируют совместными представлениями всех данных



# Проблемы в данных

- Неполнота информации (отсутствуют параметры товаров);
- Разные стандарты заполнения параметров;
- Англицизмы, сокращения, опечатки;
- Высокие требования к качеству;
- Большая схожесть между разными товарами.

*Сложные, непривычные для обычных пользователей товары с сильно выраженной спецификой. Например, так выглядят названия товаров: «ВВГнг(А)-LS 4х6,0<sup>13</sup>+1х4,0 1Кв, ТУ 16.К71-310-2001».*

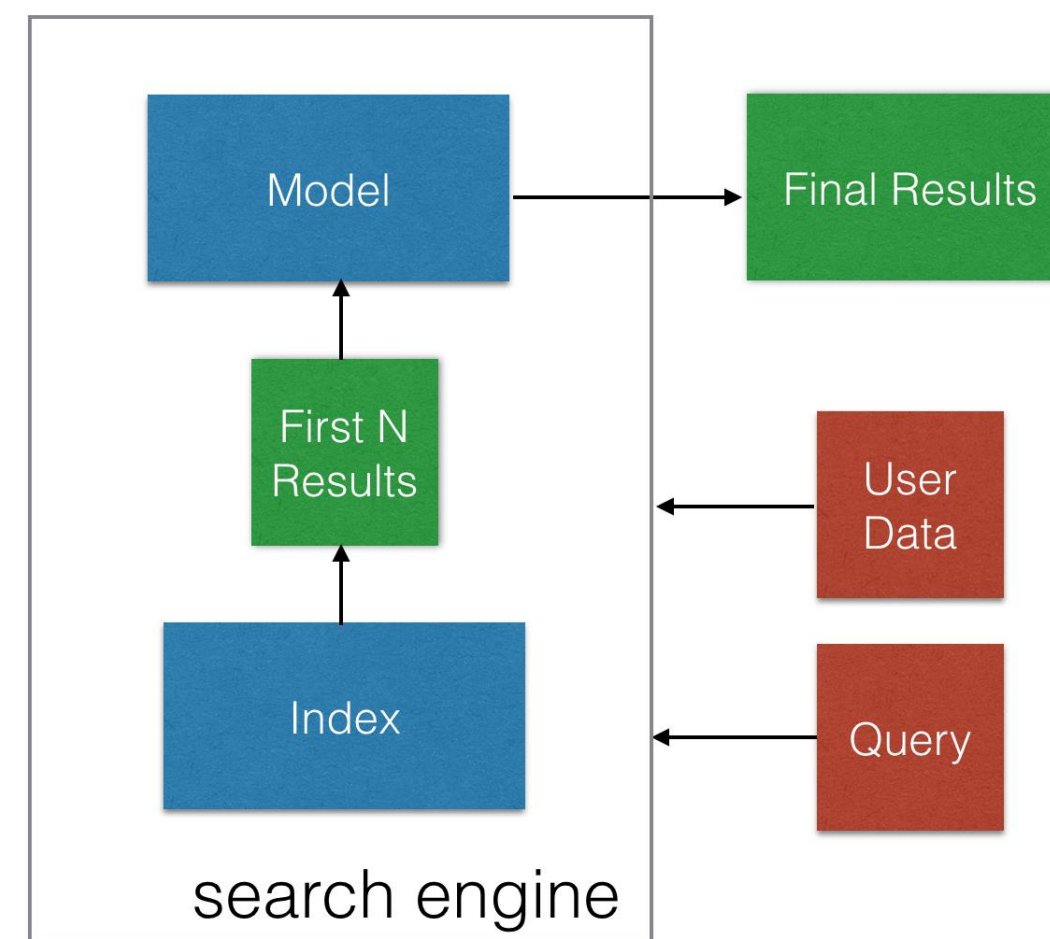
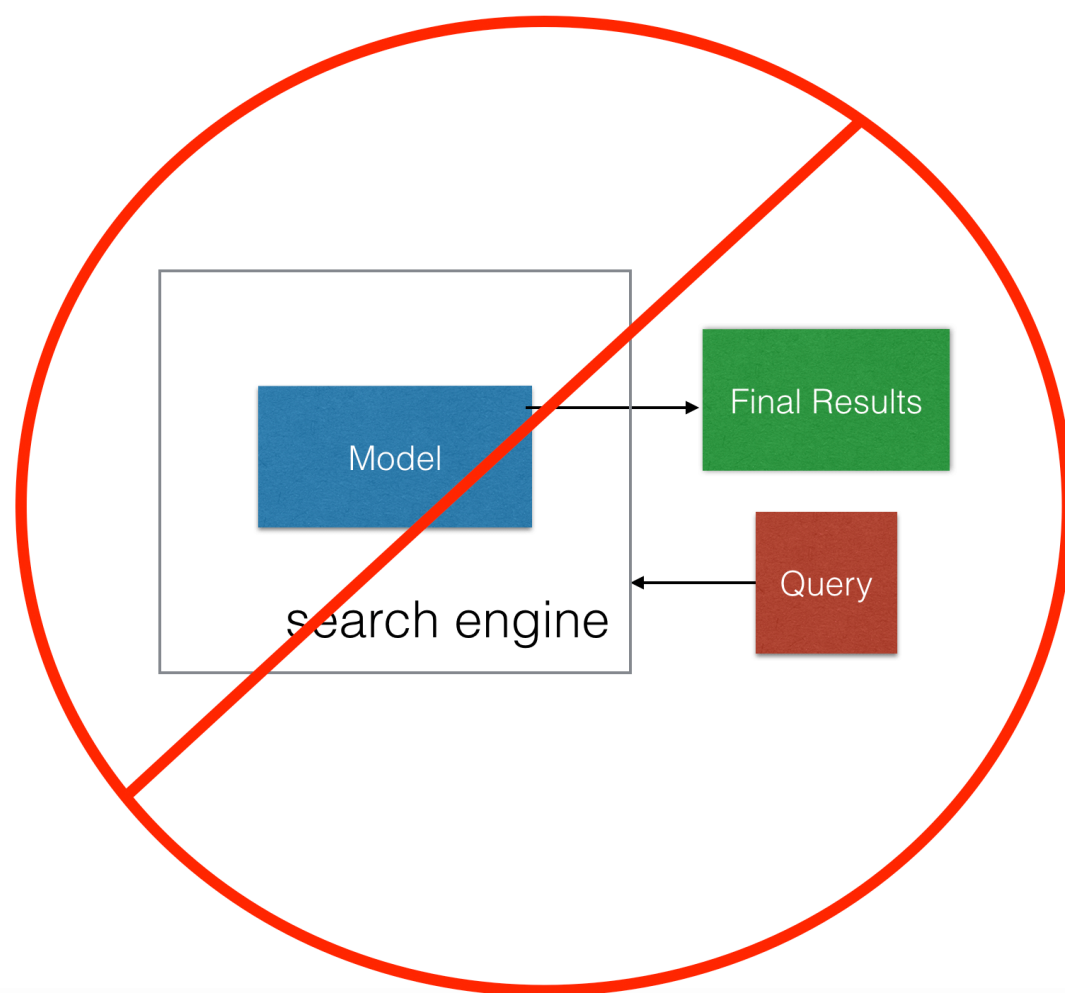
*На сайте производителя: «Посудомоечная машина ВЮ серия Economy qwerty123456 »*

*На сайте ритейлера: «Посудомоечная машина Economy (QWERTY123456) »*




# Пайплайн матчинга

- Поиск и удаление дубликатов в базе документов;
- Кластеризация входного потока запросов;
- Замена товаров из корзины пользователя.



# Поиск кандидатов

Разбиение пространства поиска



FAISS, Annoy, NMSLib  
(ANN)


العربية  
العربية - Поиск Google  
العربية بين يديك  
العربية بين يديك **скачать**  
العربية بين يدي أولادنا **pdf**  
العربية **перевод русский**

Эвристики



02

# Метрики в задаче ранжирования



# Метрики в ранжировании

**Качество/точность** — *насколько аккуратна система ранжирования?*

Измеряем возможности системы ранжировать релевантные документы выше нерелевантных.

**Эффективность** — *насколько быстро выдается ответ? Какое количество ресурсов необходимо для формирования ответа?*

Измеряем затраты на память и время формирования ответа.

**Удобство использования** — *насколько полезна система для решения задач?*


Пользовательские ощущения, UX.

17

## Оценка качества ранжирования

- Зафиксированный набор документов;
- Зафиксированный набор запросов;
- Оценки релевантности пар (в идеале оценки даются пользователями системы);
- Наборы должны быть репрезентативными.

# Оценка по топу – metric@k



How many selected items are relevant?

$$\text{Precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$

How many relevant items are selected?

$$\text{Recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$

## Precision

**Precision** — доля объектов, отнесённых классификатором к положительным и действительно являющимися положительными.

**relevant documents** — релевантные документы

**retrieved documents** — выданные документы

$$\text{precision} = \frac{|\{\text{relevant documents}\} \cap |\{\text{retrieved documents}\}|}{|\{\text{retrieved documents}\}|}$$

## Recall

**Recall** показывает, какую долю объектов положительного класса из всех объектов положительного класса нашёл алгоритм.

$$\text{recall} = \frac{|\{\text{relevant documents}\} \cap |\{\text{retrieved documents}\}|}{|\{\text{relevant documents}\}|}$$

## Fb-мера

$F_\beta$ -мера — агрегированный критерий качества **precision** и **recall**, где  $\beta$  показывает вес точности в метрике.

$F_1$  — среднее гармоническое **precision** и **recall** при  $\beta = 1$ .

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{precision} \cdot \text{recall}}{(\beta^2 \cdot \text{precision}) + \text{recall}}$$



# PR-кривая


## Алгоритм построения кривой

- 1. Сортируем предсказания по убыванию релевантности.
- 2. Считаем значение точности и полноты по первой паре.
- 3. Понижаем значение порога, чтобы выше порога было две пары.
- 4. Повторяем до тех пор, пока не добавим все элементы.
- 5. Опционально применить отсечение (Recall@Precision=N).

ID оффера	ID модели	Предсказание формулы	Правильный ответ
a01	1	6.4	1
a01	3	0.7	0
b02	2	0.6	1
c03	2	-0.8	0


Метрикой будет площадь под PR-кривой (*PR-AUC*)

19



# Оценка качества по PR

- PR-auc
- PR-auc@N



# Оценка качества ранжирования

**Average Precision (AP)** показывает, насколько много релевантных объектов сконцентрировано среди самых высоко оценённых. Чувствительна к порядку ранжирования в топе.

$$AP = \sum_K (Recall@k - Recall@[k - 1]) \cdot Precision@k$$

MAP – среднее AP по всем запросам Q

$$MAP = \frac{\sum_{q=1}^Q AP(q)}{Q}$$

k	Document ID	Predicted Relevance	Actual Relevance
1	06	0.90	Relevant (1.0)
2	03	0.85	Not Relevant (0.0)
3	05	0.71	Relevant (1.0)
4	00	0.63	Relevant (1.0)
5	04	0.47	Not Relevant (0.0)
6	02	0.36	Relevant (1.0)
7	01	0.24	Not Relevant (0.0)
8	07	0.16	Not Relevant (0.0)

Релевантных	Сумма
1	0 + 1/1 = 1
1	1
2	1 + 2/3 = 1,67
3	1,67 + 3/4 = 2,42
3	2,42
4	2,42 + 4/6 = 3,08
4	3,08
4	3,08

# Многоуровневый пример

Уровни релевантности:

1. Нерелевантно;
2. В целом релевантно;
3. Очень релевантно, точное соответствие.

	Gain
D1	3
D2	2
D3	1
D4	1
D5	3
D6	1
D7	2

# Многоуровневый пример

Уровни релевантности:

- 1. Нерелевантно;
- 2. В целом релевантно;
- 3. Очень релевантно, точное соответствие.

	Gain	Cumulative Gain
D1	3	3
D2	2	3+2
D3	1	3+2+1
D4	1	3+2+1+1
D5	3	3+2+1+1+3
D6	1	3+2+1+1+3+1
D7	2	3+2+1+1+3+1+2



# Многоуровневый пример

Уровни релевантности:

- 1. Нерелевантно;
- 2. В целом релевантно;
- 3. Очень релевантно, точное соответствие.

	Gain	Cumulative Gain	$\log_2(k+1)$	Discounted Cumulative Gain
D1	3	3		3
D2	2	3+2		$3 + 2/\log(3)$
D3	1	3+2+1		$3 + 2/\log(3) + 1/\log(4)$
D4	1	3+2+1+1		$3 + 2/\log(3) + 1/\log(4) + 1/\log(5)$
D5	3	3+2+1+1+3		...
D6	1	3+2+1+1+3+1		...
D7	2	3+2+1+1+3+1+2		$DCD@7 = 3 + 2/\log(3) + \dots + 2/\log(8)$

# Многоуровневый пример

Уровни релевантности:

1. Нерелевантно;
2. В целом релевантно;
3. Очень релевантно, точное соответствие.

	Gain	Discounted Cumulative Gain
D1	3	3
D2	2	$3 + 2/\log(3)$
D3	1	$3 + 2/\log(3) + 1/\log(4)$
D4	1	$3 + 2/\log(3) + 1/\log(4) + 1/\log(5)$
D5	3	...
D6	1	...
D7	2	$\text{DCD}@7 = 3 + 2/\log(3) + \dots + 2/\log(8) \sim 7.38$

# Многоуровневый пример

Уровни релевантности:

- 1. Нерелевантно;
- 2. В целом релевантно;
- 3. Очень релевантно, точное соответствие.

## Normalized DCG

$$nDCG@k = \frac{DCG@k}{IdealDCG@k}$$
$$nDCG \in [0, 1]$$

	Gain	Discounted Cumulative Gain	
D1	3	3	
D2	2	$3 + 2/\log(3)$	
D3	1	$3 + 2/\log(3) + 1/\log(4)$	
D4	1	$3 + 2/\log(3) + 1/\log(4) + 1/\log(5)$	
D5	3	...	
D6	1	...	
D7	2	$DCD@7 = 3 + 2/\log(3) + \dots + 2/\log(8) \sim 7.38$	$nDCD@7 = 0.942$
		$IdealDCD@7 = 3 + 3/\log(3) + \dots + 1/\log(8) \sim 7.83$	

# PFound

Значение метрики будет **оценкой вероятности** найти релевантный результат в выдаче модели:

$$pfound = \sum_{i=1}^n pLook[i] \cdot pRel[i]$$

$pLook[i]$  — вероятность посмотреть  $i$ -й документ из списка

$pRel[i]$  — вероятность того, что  $i$ -й документ окажется релевантным (например, 0%, 50%, 100% для трёхуровневой шкалы).

Для расчёта  $pLook[i]$  используются два предположения:

- результаты ранжирования просматриваются сверху вниз
- процесс прекращается в случае нахождения релевантного результата либо без каких-то определённых причин (например, если "надоело")

$$pLook[i] = pLook[i - 1] \cdot (1 - pRel[i - 1]) \cdot (1 - pBreak)$$

$pBreak$  — вероятность прекращения просмотра выдачи

# Базовые метрики

Среднеобратный ранг (Mean reciprocal rank, **MRR**) — среднее гармоническое между рангами.

$$MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{rank_i}$$

Запрос	Ответы	Правильный ответ	Ранг	Обратный ранг
кочерга	кочерг, кочергей, <b>кочерёг</b>	кочерёг	3	1/3
попадья	попадь, <b>попадей</b> , попадьеёв	попадей	2	1/2
турок	<b>турок</b> , турков, турчан	турок	1	1

$$MRR = (1/3 + 1/2 + 1) / 3 = 11/18 \sim 0.61$$



# Базовые метрики

Среднеобратный ранг (Mean reciprocal rank, **MRR**) — среднее гармоническое между рангами.

$$MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{rank_i}$$

Запрос	Ответы	Правильный ответ	Ранг	Обратный ранг
кочерга	кочерг, кочергей, <b>кочерёг</b>	кочерёг	3	1/3
попадья	попадь, <b>попадей</b> , попадьеёв	попадей	2	1/2
турок	<b>турок</b> , турков, турчан	турок	1	1

$$MRR = (1/3 + 1/2 + 1) / 3 = 11/18 \sim 0.61$$

## Kendall rank correlation coefficient

$$\tau = \frac{(\text{number of concordant pairs}) - (\text{number of discordant pairs})}{\binom{n}{2}}$$

$$\tau \in [-1, 1]$$

**number of concordant pairs** — количество согласованных пар (верно упорядоченных)

**number of discordant pairs** — количество согласованных пар (неверно упорядоченных)

$$\binom{n}{2} = \frac{n(n-1)}{2} \text{ — биномиальный коэффициент}$$


Часто используется в статистике для оценки **ранговых корреляций**.

# Промежуточные выводы

- Имеем привилегию отказаться от выдачи;
- Важны только самые-самые первые результаты (1-3);
- Огромный дисбаланс (от нуля до тысяч матчей);
- Финальное решение можно предоставить классификатору;
- Отдельные метрики для разных этапов пайплайна;
- Метрики могут агрегироваться на уровне одного SKU;



03



# Подходы решения задачи ранжирования

# Подходы к решению задачи ранжирования

## 1. Pointwise (поточечный)

- Функция ошибки по конкретному объекту (в пару к запросу).

$$\sum_{q,j} l(f(\mathbf{x}_j^q), r_j^q) \rightarrow \min$$

## 2. Pairwise (попарный)

- Функция ошибки по паре объектов (в пару к запросу).

$$\sum_q \sum_{i,j: r_i^q > r_j^q} l(f(\mathbf{x}_i^q) - f(\mathbf{x}_j^q)) \rightarrow \min$$

32

## 3. Listwise (списочный)

- Функция ошибки на всём списке документов (для конкретного запроса).

$$l(\{f(\mathbf{x}_j^q)\}_{j=1}^{m_q}, \{r_j^q\}_{j=1}^{m_q}) \rightarrow \min$$

# Pointwise - BM25

$$score(D, Q) = \sum_{i=1}^n IDF(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot (1 - b + b \cdot \frac{|D|}{avgdl})}$$

$f(q_i, D)$  — частота слова  $Q_i$  в документе  $D$  (запрос  $Q_i$  содержит в себе слова  $Q_1, \dots, Q_n$ )

$$IDF = \log \frac{N}{n(q_i)}$$

$$IDF(q_i) = \ln\left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1\right) \quad \text{Сглаженный вариант IDF}$$

## Недостатки BM25

- Значение отрицательно, если производится расчёт для слова, входящего более чем в половину документов (частотные слова, stop-слова);
- Функция сконструирована вручную

# Pairwise

$A > B$  — документ A должен быть отранжирован выше документа B

$P(A > B)$  — вероятность того, что документ A должен быть отранжирован выше, чем B

$f : R^d \mapsto R$  — функция отображения документа в меру релевантности

$f(x_1) > f(x_2)$  — модель оценила релевантность одного документа выше другого

Функция потерь

$$C_{ij} \equiv C(o_{ij}) = -\bar{P}_{ij} \log P_{ij} - (1 - \bar{P}_{ij}) \log(1 - P_{ij})$$

$P_{ij}$  — предсказание модели

$\bar{P}_{ij}$  — целевая метка (*target*)

# Pairwise

Функция потерь

$$C_{ij} \equiv C(o_{ij}) = -\bar{P}_{ij} \log P_{ij} - (1 - \bar{P}_{ij}) \log(1 - P_{ij})$$

$P_{ij}$  — предсказание модели

$\bar{P}_{ij}$  — целевая метка (*target*)

$o_i \equiv f(x_i)$  — предсказание нашего алгоритма для одного объекта (*логит* или *скор*)

$o_{ij} \equiv f(x_i) - f(x_j)$  - сходство порядка в ранжировании

35

$P_{ij} = \frac{e^{o_{ij}}}{1 + e^{o_{ij}}}$  — функция отображения предсказания (логита) в вероятность.

Тогда функция потерь

$$C_{ij} = -\bar{P}_{ij} o_{ij} + \log(1 + e^{o_{ij}})$$




# Pairwise

Тогда функция потерь

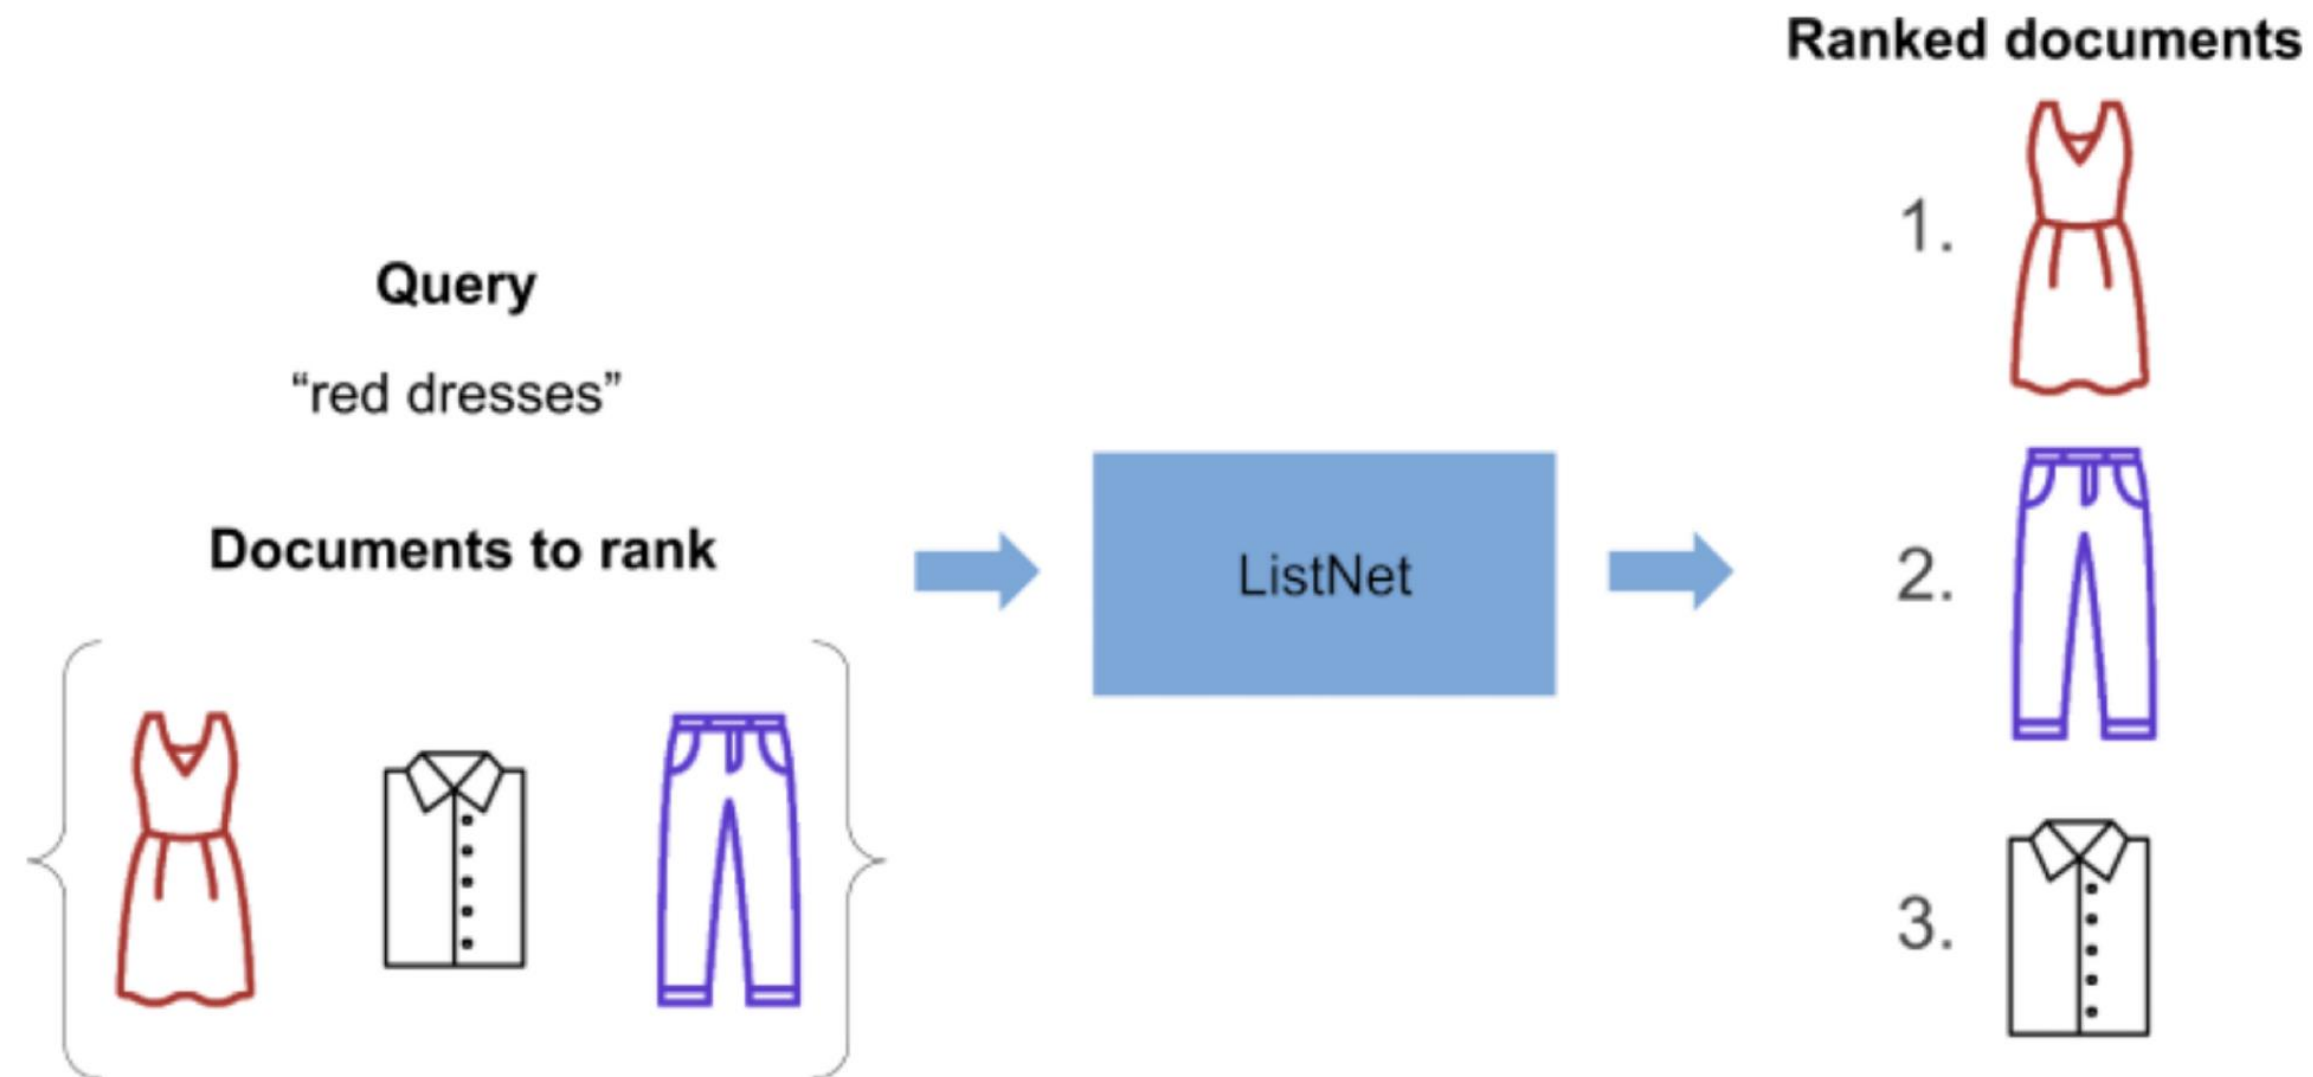
$$C_{ij} = -\bar{P}_{ij}o_{ij} + \log(1 + e^{o_{ij}})$$

- Линейная асимптотика более робастна при шумных метках.
- При таргете 0.5 симметрична, позволяет тренироваться на объектах одного ранга.



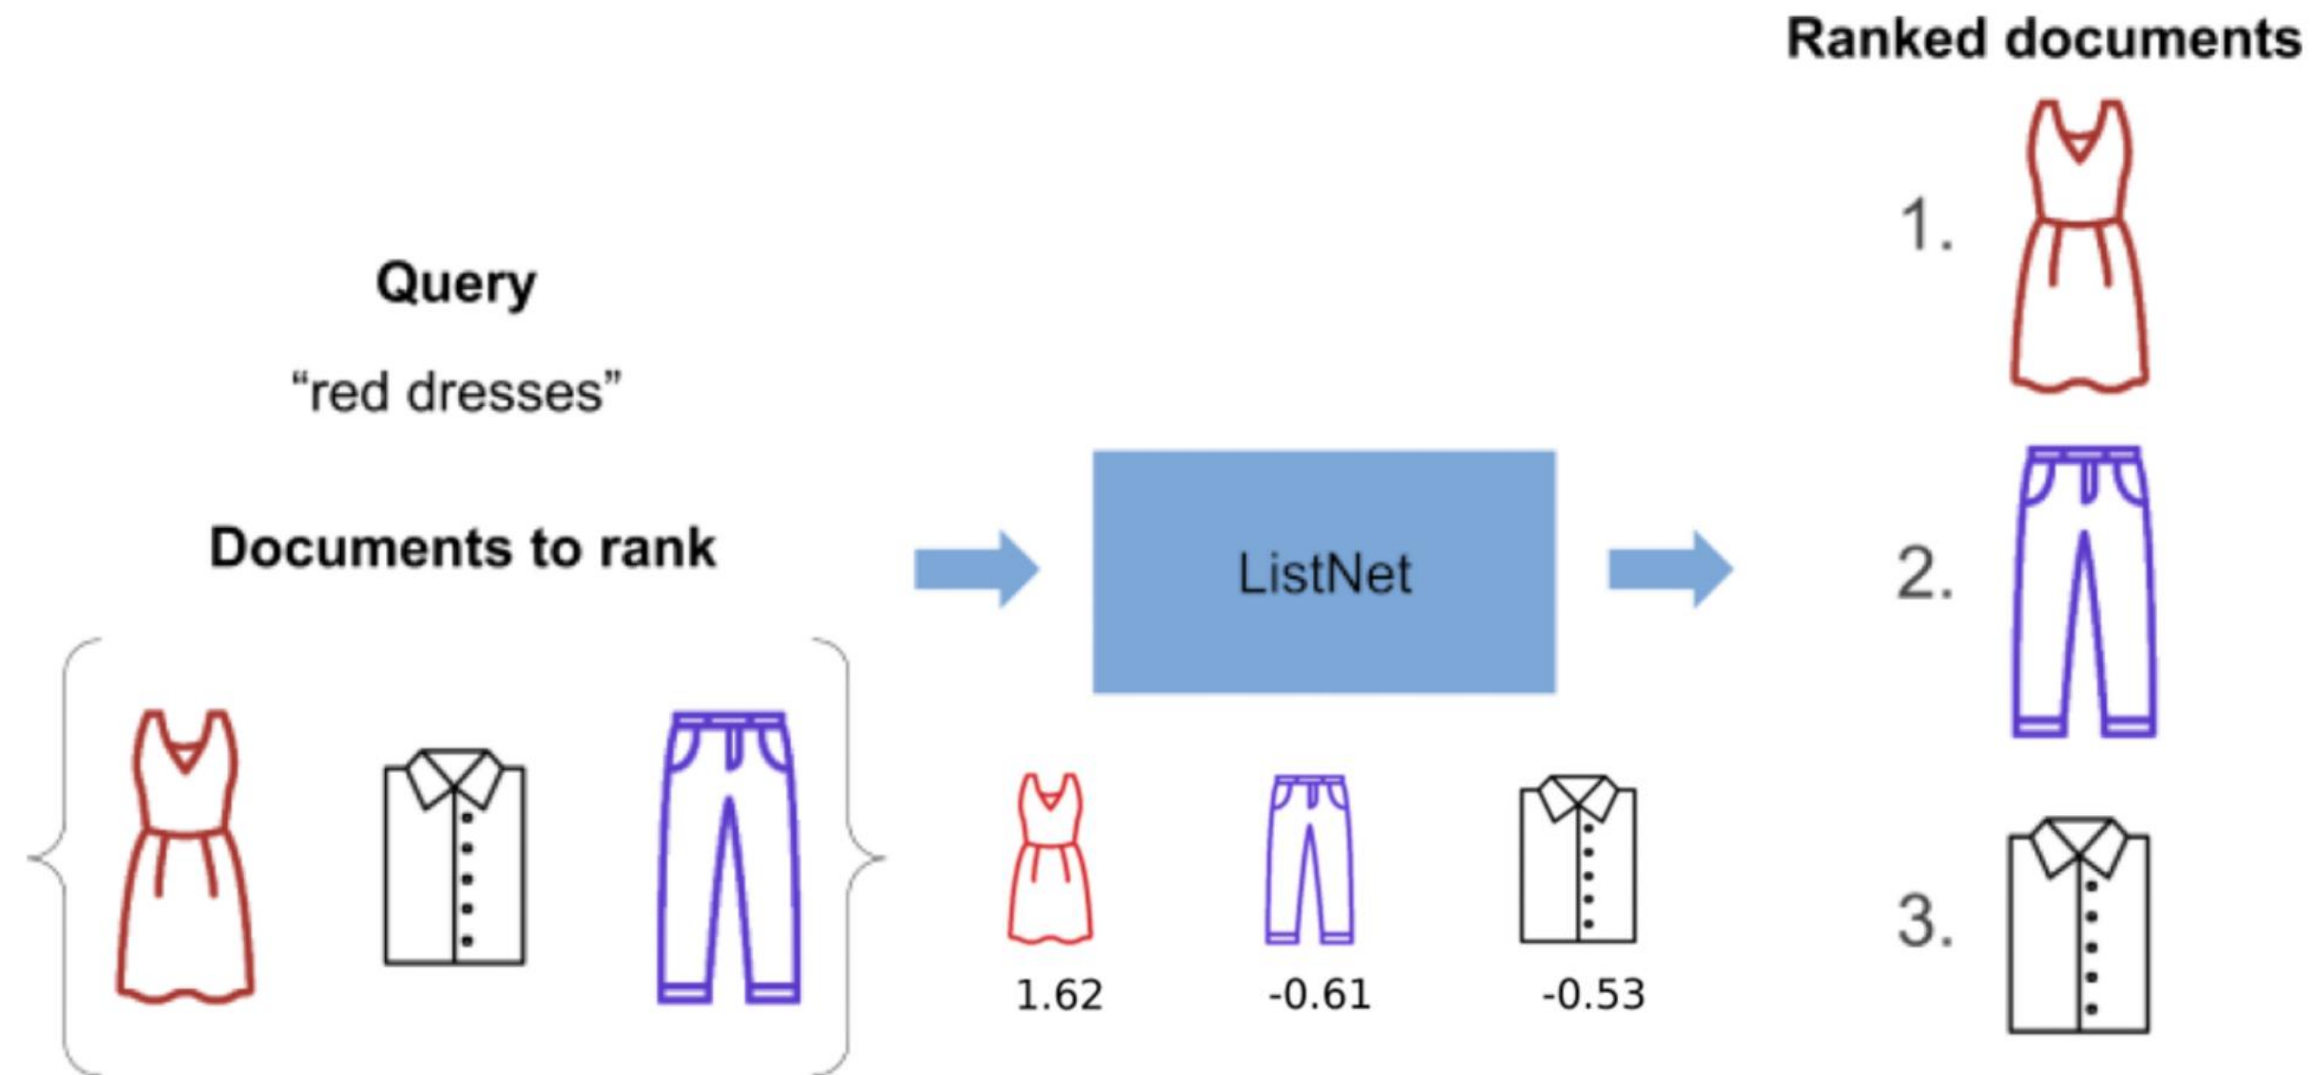
# Listwise

Хотим, чтобы алгоритм учился на всем множестве релевантных документах для запроса



# Listwise

Хотим получить распределение вероятностей похожее на нашу разметку




# Listwise

Сделаем предположение, что **любая перестановка документов возможна**, но при этом разные перестановки могут иметь **разную вероятность**

$\pi = \langle \pi(1), \pi(2), \dots, \pi(n) \rangle$  перестановка

$$P_s(\pi) = \prod_{j=1}^n \frac{\phi(s_{\pi(j)})}{\sum_{k=j}^n \phi(s_{\pi(k)})}$$

- вероятность возникновения такой перестановки



# Listwise

$$P_s(\pi) = \prod_{j=1}^n \frac{\phi(s_{\pi(j)})}{\sum_{k=j}^n \phi(s_{\pi(k)})}$$



1.62



-0.61



-0.53

$$P_s(\pi) = \prod_{j=1}^n \frac{\phi(s_{\pi(j)})}{\sum_{k=j}^n \phi(s_{\pi(k)})} = \frac{\phi(s_1)}{\phi(s_1) + \phi(s_2) + \phi(s_3)} \cdot \frac{\phi(s_2)}{\phi(s_2) + \phi(s_3)} \cdot \frac{\phi(s_3)}{\phi(s_3)} =$$

$$\frac{e^{s_{dress}}}{e^{s_{dress}} + e^{s_{pants}} + e^{s_{shirt}}} \cdot \frac{e^{s_{pants}}}{e^{s_{pants}} + e^{s_{shirt}}} \cdot \frac{e^{s_{shirt}}}{e^{s_{shirt}}} = 0.3917 \text{ (39.17\%)}$$

Выводы для метода:

- Наибольшая вероятность у перестановки, в которой объекты отсортированы в порядке убывания.
- Наименьшая вероятность у перестановки, в которой объекты отсортированы в порядке возрастания.
- Количество перестановок равно n!.



















Rank 1	Rank 2	Rank 3	
			42.59%
			39.17%
			8.58%
			0.92%
			7.83%
			0.91%

# Listwise

Выводы для метода:

- Наибольшая вероятность у перестановки, в которой объекты отсортированы в порядке убывания.
- Наименьшая вероятность у перестановки, в которой объекты отсортированы в порядке возрастания.
- Количество перестановок равно  $n!$  – медленно будем обучать...

41

Rank 1	Rank 2	Rank 3	
			42.59%
			39.17%
			8.58%
			0.92%
			7.83%
			0.91%



# Listwise

Выводы для метода:

- Наибольшая вероятность у перестановки, в которой объекты отсортированы в порядке убывания.
- Наименьшая вероятность у перестановки, в которой объекты отсортированы в порядке возрастания.
- Количество перестановок равно  $n!$
- TopOne Probability – вероятность того, что объект  $j$  находится на первом месте в отранжированном списке



















$$P_s(j) = \sum_{\pi(1)=j, \pi \in \Omega_n} P_s(\pi) \cdot \text{все перестановки, где первый } j$$

42


$$P_s(j) = \frac{\phi(s_j)}{\sum_{k=1}^n \phi(s_k)}$$

Сводим задачу к оценке распределений, что  $j$  объект в разметке должен иметь заданную вероятность

$$L(y^{(i)}, z^{(i)}) = - \sum_{j=1}^n P_{y^{(i)}}(j) \log(P_{z^{(i)}}(j)),$$

Rank 1	Rank 2	Rank 3	
			42.59%
			39.17%
			8.58%
			0.92%
			7.83%
			0.91%





Место для ваших  
вопросов